⭐ OASIS-1 인지노화 데이터 분석으로 배우는 R

📊 R 기초 지식 정리

1. 데이터 불러오기 & 정제

핵심 함수

```
read_csv()      # CSV 파일 불러오기 (tidyverse)
rename()        # 컬럼명 변경
select()        # 필요한 컬럼만 선택
mutate()        # 새 컬럼 만들기 / 기존 컬럼 변환
drop_na()       # 결측값 있는 행 제거
as.factor()     # 범주형 변수로 변환
as.numeric()    # 수치형 변수로 변환
```

왜 중요한가

- 실제 데이터는 항상 지저분함 → 분석 전 정제가 필수
- `M/F` 같은 특수문자 포함 컬럼명은 백틱(` `)으로 감싸야 함
- 결측값을 제거하지 않으면 회귀분석 오류 발생

파이프 연산자 `%>%`

```
# 이 두 코드는 같은 의미
df %>% select(Age, MMSE) %>% drop_na()

drop_na(select(df, Age, MMSE))  # 읽기 어려움
```

> 💡 왼쪽 결과를 오른쪽 함수의 첫 번째 인자로 넘긴다

2. 기술통계

핵심 함수

```
summary()          # 최솟값, 최댓값, 평균, 중앙값
mean()             # 평균
sd()               # 표준편차
table()            # 범주형 변수 빈도표
psych::describe() # 더 자세한 기술통계 (왜도, 첨도 포함)
```

이번 분석에서 확인한 것

변수	의미	확인 이유
Age	나이	샘플 연령 분포 파악
MMSE	인지점수 (0~30)	종속변수 분포 확인
nWBV	정규화 전뇌 부피	주요 예측변수
CDR	치매 등급	집단 구분 변수

---

3. 상관관계

핵심 함수

```
cor(x, y, use = "complete.obs")   # 두 변수 상관계수
cor(df, use = "complete.obs")     # 여러 변수 상관행렬
```

해석 기준

r 값	해석
0.1 ~ 0.3	약한 상관
0.3 ~ 0.5	중간 상관
0.5 이상	강한 상관
음수	반비례 관계

> 💡 상관관계 ≠ 인과관계. 나이와 MMSE가 상관있어도 나이가 직접 인지저하를 "일으키는지"는 회귀분석으로 따로 확인해야 함

4. 시각화 (ggplot2)

ggplot2 기본 구조

```
ggplot(data, aes(x = 변수1, y = 변수2)) +  # 데이터 & 축 지정
  geom_point() +                              # 점 그래프
  geom_smooth(method = "lm") +                # 회귀선 추가
  labs(title = "제목", x = "x축", y = "y축") +  # 레이블
  theme_minimal()                             # 테마
```

이번에 쓴 geom

함수	용도
`geom_point()`	산점도
`geom_smooth(method="lm")`	선형 회귀선 + 신뢰구간
`geom_boxplot()`	집단별 분포 비교

aes() 안에서 쓸 수 있는 것들

```
aes(x, y)              # 기본 축
aes(color = Sex)       # 색상으로 집단 구분
aes(alpha = 0.6)       # 투명도
aes(size = Age)        # 크기로 변수 표현
```

5. 선형회귀 (lm)

기본 문법

```
model <- lm(종속변수 ~ 예측변수1 + 예측변수2, data = df)
summary(model)
```

summary() 결과 읽는 법

```
Coefficients:
            Estimate  Std. Error  t value  Pr(>|t|)
```

```
(Intercept)  30.123     1.234      24.41   <2e-16 ***
nWBV          8.456     2.341       3.61   0.0003 ***
Age          -0.032     0.012      -2.67   0.0079 **
```

항목	의미
`Estimate`	회귀계수 (기울기)
`Std. Error`	표준오차
`t value`	t 통계량
`Pr(>	t
`***`	p < 0.001 (유의미)
`R-squared`	모델이 분산의 몇 %를 설명하는가

이번 분석 모델 4개

```
model1 <- lm(nWBV ~ Age, data = df_cog)
# → 나이가 많을수록 뇌 부피 감소하는가?

model2 <- lm(MMSE ~ nWBV, data = df_cog)
# → 뇌 부피가 클수록 인지점수 높은가?

model3 <- lm(MMSE ~ nWBV + Age, data = df_cog)
# → 나이를 통제해도 뇌 부피가 MMSE를 설명하는가?

model4 <- lm(MMSE ~ nWBV + Age + CDR + Sex + Educ, data = d
f_cog)
# → 여러 변수를 동시에 통제한 full model
```

공변량 통제가 왜 중요한가

> 나이가 많을수록 뇌 부피도 줄고 인지점수도 낮아진다면,
> 뇌 부피 → 인지점수 관계는 **나이의 영향**일 수 있다.
> model3처럼 Age를 함께 넣으면 나이 효과를 통제한 뒤
> 뇌 부피의 순수한 영향만 볼 수 있다.

---

6. 결과 저장

```
capture.output(summary(model), file = "결과.txt")
# → 회귀분석 결과를 텍스트 파일로 저장

ggsave("그래프.png", width = 8, height = 5, dpi = 150)
# → ggplot 그래프를 이미지로 저장
```

7. 자주 나오는 에러 & 해결법

에러	원인	해결
`Column M.F doesn't exist`	컬럼명에 특수문자	백틱으로 감싸거나 `rename()`
`cannot open connection`	파일 경로 틀림	`/content/파일명.csv` 확인
`NA` 결과	결측값 포함	`use = "complete.obs"` 또는 `drop_na()`
`object not found`	변수명 오타	대소문자 구분 확인

8. 핵심 패키지 한눈에

패키지	용도
`tidyverse`	데이터 정제 & 조작 전체 묶음
`ggplot2`	시각화 (tidyverse에 포함)
`psych`	심리학/뇌과학 연구용 기술통계
`broom`	회귀분석 결과를 데이터프레임으로 변환
`lme4`	혼합효과모델 (다음 단계)